

Báo cáo Đề xuất Nghiên cứu

Cắt tỉa Bằng chứng Định hướng Microglia (MDEP)
thông qua Hệ thống Đa tác nhân Nhận thức Bất định

Tổng hợp từ nội dung đề tài

Ngày 8 tháng 5 năm 2026

Tóm tắt nội dung

Sự phát triển vũ bão của các hệ thống học sâu đã thiết lập những tiêu chuẩn hiệu năng mới cho hàng loạt tác vụ nhận thức của trí tuệ nhân tạo. Tuy nhiên, rào cản lớn nhất đối với việc triển khai các mô hình này trong những lĩnh vực rủi ro cao như y tế hay xe tự lái vẫn là sự thiếu hụt khả năng định lượng bất định một cách đáng tin cậy. Các mạng nơ-ron truyền thống thường mắc phải hiện tượng tự tin thái quá, trong khi học sâu bằng chứng (Evidential Deep Learning – EDL) nổi lên như một hướng tiếp cận đột phá nhờ khả năng mô hình hóa trực tiếp bất định nhận thức và bất định nội tại chỉ qua một lần truyền thuận.

Dẫu vậy, các kiến trúc EDL hiện tại vẫn là các mạng tĩnh, dẫn tới việc lãng phí tham số để hấp thụ “bằng chứng rác” từ các đặc trưng nhiễu. Song song với đó, các phương pháp huấn luyện mạng thưa động (Dynamic Sparse Training – DST) lại hoàn toàn mù mờ trước tín hiệu bất định và thường gặp khủng hoảng tối ưu trên không gian rời rạc. Báo cáo này đề xuất khung lý thuyết *Microglial-Driven Evidential Pruning* (MDEP), trong đó tương tác giữa Microglia và Astrocyte được số hóa thành một hệ tối ưu hóa kiến trúc đa tác nhân. Thông qua nối lỏng liên tục bằng điểm số tiềm ẩn, xấp xỉ Taylor bậc một và Smoothed Straight-Through Estimator, MDEP điều khiển quá trình cắt tỉa và mọc mới kết nối dựa trên đạo hàm của sự bất định. Dưới góc nhìn xấp xỉ ngẫu nhiên có chệch, đề tài hướng tới các đảm bảo toán học về hội tụ hình thái và kháng sập lớp. Khi kết hợp với chuẩn thưa NVIDIA 2:4 và hàm suy hao Evidential Focal Loss (EFL) được đề xuất riêng cho dữ liệu siêu mất cân bằng, MDEP hứa hẹn mang lại một mô hình vượt trội về định lượng bất định, khả năng kháng nhiễu và tăng tốc phân cứng thực tế.

1 Bối cảnh nghiên cứu và động cơ đề tài

Học sâu hiện đạt thành tích rất cao trên nhiều bài toán nhận dạng, phân loại và ra quyết định. Tuy nhiên, các mô hình mạng nơ-ron sâu truyền thống thường sinh ra dự đoán có độ tự tin cao ngay cả khi đầu vào nhiễu, lệch miền dữ liệu hoặc nằm ngoài phân phối huấn luyện. Đây là một điểm yếu nghiêm trọng trong các ứng dụng có rủi ro cao, nơi sai số không chỉ làm giảm hiệu năng mà còn có thể dẫn đến hậu quả lâm sàng hoặc an toàn nghiêm trọng.

Trong bối cảnh đó, định lượng bất định (Uncertainty Quantification – UQ) trở thành một yêu cầu trung tâm. EDL cung cấp một lựa chọn hấp dẫn nhờ biểu diễn đầu ra dưới dạng bằng chứng và tham số hóa phân phối Dirichlet, qua đó tách bạch được bất định nhận thức và bất định nội tại với chi phí suy luận thấp. Dù vậy, EDL hiện vẫn chủ yếu dựa trên các mạng tĩnh, chưa tận dụng được khả năng tự tái cấu trúc để loại bỏ các thành phần hấp thụ “bằng chứng rác” từ nhiễu.

Ở chiều ngược lại, các phương pháp mạng thưa động (Dynamic Sparse Training – DST) như RigL hay SNIP cho thấy tiềm năng giảm chi phí tính toán bằng việc cắt tỉa và tái sinh kết nối trong quá trình huấn luyện. Tuy nhiên, các phương pháp này gần như chỉ dựa vào độ lớn trọng số hoặc gradient mất mát, mà không xét đến tín hiệu bất định. Hệ quả là mô hình có thể duy trì những kết nối đang “ghi nhớ nhiều” và vô tình khuếch đại các dự đoán sai nhưng rất tự tin.

Đề tài MDEP được đề xuất nhằm lấp khoảng trống giữa hai hướng nghiên cứu trên: kết hợp sức mạnh của EDL trong biểu diễn bất định với tính thích nghi cấu trúc của DST để tạo ra một mô hình vừa thưa, vừa ổn định, vừa đáng tin cậy.

2 Bối cảnh và tuyên bố vấn đề

2.1 Điểm mù của các thuật toán cắt tỉa và mạng thưa động

Trong nỗ lực giảm chi phí lưu trữ và tính toán, các kỹ thuật DST như RigL hay SNIP đã chứng minh rằng việc cắt và mọc kết nối liên tục có thể duy trì hiệu năng với số tham số thấp hơn đáng kể. Tuy nhiên, các phương pháp này tồn tại một điểm mù hệ thống: chúng gần như không có khả năng nhận thức sự bất định. Trong môi trường dữ liệu chứa nhiễu, một trọng số có độ lớn cao chưa chắc phản ánh tri thức hữu ích mà có thể chỉ là dấu hiệu cho việc mô hình đang ghi nhớ nhiễu cục bộ. Khi thuật toán ưu tiên giữ lại những trọng số như vậy, nó vô tình bảo vệ các nơ-ron gây ra dự đoán sai nhưng lại rất tự tin.

2.2 Sự tĩnh tại cấu trúc của học sâu bằng chứng

EDL giải quyết vấn đề tự tin thái quá bằng cách tham số hóa phân phối Dirichlet trên không gian bằng chứng. Dù các biến thể hiện đại như $\mathcal{I}$ -EDL đã khắc phục được hạn chế về bất định nhận thức không triệt tiêu, hệ sinh thái EDL nhìn chung vẫn mắc kẹt trong trạng thái “tĩnh tại cấu trúc”. Khi dữ liệu chứa nhiễu hoặc tín hiệu mơ hồ, một mạng tĩnh buộc phải sử dụng thêm tham số để ghi nhớ các đặc trưng không đáng tin nhằm tiếp tục giảm hàm mất mát. Trong ngữ cảnh này, MDEP được định vị như một kiến trúc trực giao, đóng vai trò “người dọn dẹp cấu trúc” để các hàm suy hao bằng chứng có thể hoạt động trên một hình thái mạng thưa và sạch hơn.

2.3 Rào cản phần cứng và khủng hoảng tối ưu rời rạc

Phần lớn các nghiên cứu DST tạo ra sự thừa thớt phi cấu trúc nên không mang lại tốc độ suy luận thực tế đáng kể trên GPU. Đồng thời, việc tối ưu trực tiếp trên mặt nạ nhị phân $\{0, 1\}$ thường phá vỡ luồng gradient, đặc biệt khi mạng trở nên cực thưa, từ đó dẫn đến nguy cơ sập lớp nếu dữ liệu huấn luyện chứa nhiễu cục bộ hoặc tín hiệu bất ổn.

2.4 Giới hạn của sự tương đồng sinh học

Cần nhấn mạnh rằng MDEP không phải là một mô hình mô phỏng sinh học theo nghĩa mạng nơ-ron gai. Tương tác Microglia–Astrocyte trong đề tài chỉ được sử dụng như một phép loại suy định tuyến thuật toán. Thay vì mô phỏng tín hiệu điện hóa phụ thuộc hoạt động, MDEP ánh xạ các tín hiệu “chăm sóc” và “điều phối” này thành các đạo hàm thống kê của bất định

nội tại u_a và bất định nhận thức u_e , bảo đảm tương thích hoàn toàn với đồ thị tính toán lan truyền ngược trong học sâu hiện đại.

Từ các vấn đề trên, câu hỏi nghiên cứu trung tâm là: *liệu có thể xây dựng một khung cắt tĩa động nhận thức bất định, vừa có bảo đảm toán học, vừa tận dụng được tăng tốc phần cứng, đồng thời nâng cao độ tin cậy của mô hình trên dữ liệu nhiễu và mất cân bằng hay không?*

3 Mục tiêu nghiên cứu

Mục tiêu tổng quát của đề tài là xây dựng và kiểm chứng một khung cắt tĩa bằng chứng định hướng Microglia, cho phép tối ưu đồng thời cấu trúc mạng, hiệu năng dự đoán, độ tin cậy định lượng bất định và hiệu quả tính toán thực tế.

Các mục tiêu cụ thể gồm:

- Thiết lập đảm bảo toán học cho quá trình tối ưu cấu trúc bằng nối lỏng liên tục và lý thuyết xấp xỉ ngẫu nhiên có chệch.
- Định hình khung tối ưu hóa đa tác nhân, trong đó Microglia và Astrocyte là hai tác nhân giải tích cùng hướng tới cực tiểu hóa sai số định cỡ.
- Giải quyết nghịch lý bất định cục bộ bằng cách áp dụng Smoothed STE để tính toán đạo hàm bất định nhận thức theo từng nơ-ron.
- Đề xuất hàm Evidential Focal Loss nhằm xử lý các bộ dữ liệu siêu mất cân bằng như ISIC 2024 mà vẫn bảo toàn hình học của phân phối Dirichlet.
- Tích hợp ràng buộc thừa có cấu trúc NVIDIA 2:4 và chiến lược cập nhật khẩu hao để tăng tính khả thi trên phần cứng.

4 Cơ sở lý thuyết

4.1 Nền tảng Học sâu bằng chứng

Trong EDL, đầu ra của mạng không được hiểu trực tiếp là xác suất lớp mà là một véc-tơ bằng chứng không âm $\mathbf{e} = f(\mathbf{x}, \mathbf{W}) \geq 0$. Từ đó ta xây dựng tham số Dirichlet:

$$\boldsymbol{\alpha} = \mathbf{e} + 1, \quad S = \sum_{c=1}^K \alpha_c.$$

Hai đại lượng bất định cốt lõi được dùng trong đề tài bao gồm:

$$u_e = \frac{K}{S}$$

cho bất định nhận thức, và

$$u_a = - \sum_{c=1}^K \frac{\alpha_c}{S} (\psi(S+1) - \psi(\alpha_c+1))$$

cho bất định nội tại, với $\psi(\cdot)$ là hàm digamma.

Ý nghĩa thực tiễn của biểu diễn này là tổng bằng chứng S càng lớn thì mô hình càng tự tin; ngược lại, khi S thấp, bất định nhận thức sẽ cao. Đây chính là nền tảng để MDEP sử dụng tín hiệu bất định như một tiêu chí tái cấu trúc mạng.

4.2 Dẫn xuất tác nhân từ lựa chọn mô hình Bayes

MDEP diễn giải hành vi cắt tỉa của Microglia như một dạng lựa chọn mô hình Bayes gần đúng trên không gian cấu trúc. Việc loại bỏ một liên kết w_{ij} không chỉ tương đương với giảm số tham số, mà còn là hành động tối ưu độ phức tạp của mô hình trong nghĩa năng lượng tự do biến phân. Nhờ vậy, MDEP có thể được xem như một cơ chế xấp xỉ suy luận Bayes trên không gian topology mà không cần phụ thuộc vào lấy mẫu Monte Carlo đắt đỏ.

4.3 Nới lỏng liên tục và định lý hội tụ xấp xỉ có chệch

Không thể áp dụng trực tiếp tối ưu hóa liên tục lên mặt nạ nhị phân $M_{ij} \in \{0, 1\}$. Vì vậy, MDEP duy trì ma trận điểm số tiềm ẩn liên tục $\mathbf{S} \in \mathbb{R}^{d \times d}$ và suy ra mặt nạ nhị phân theo:

$$M_{ij}^{(t)} = H\left(S_{ij}^{(t)} - \tau_t\right).$$

Thách thức quan trọng nằm ở chỗ việc cập nhật $\mathbf{S}$ thông qua Smoothed STE tạo ra một ước lượng gradient có chệch. Do đó, định lý Robbins–Monro cổ điển không còn áp dụng trực tiếp. Đề tài sử dụng khuôn khổ xấp xỉ ngẫu nhiên có chệch, trong đó độ chệch giảm dần nhờ lịch trình ủ nhiệt $\gamma_t \rightarrow 0$ theo thời gian. Khi kết hợp với chuỗi tốc độ học ζ_t thỏa mãn

$$\sum_t \zeta_t = \infty, \quad \sum_t \zeta_t^2 < \infty,$$

và ngưỡng động $\tau_t \rightarrow \tau_{final}$ theo lịch trình cosine, ta kỳ vọng không gian trạng thái $\mathbf{S}^{(t)}$ hội tụ; kéo theo đó là sự hội tụ hình thái của mặt nạ nhị phân $\mathbf{M}^{(t)}$.

Ngoài ra, dưới phân phối khởi tạo Erdős–Rényi–Kernel và cơ chế bù trừ của Astrocyte, xác suất để một lớp l bị cắt tỉa hoàn toàn được khống chế bởi cận:

$$P\left(\sum M_l = 0\right) \leq \exp(-\Omega(N_l)),$$

qua đó cung cấp một đảm bảo lý thuyết cho khả năng kháng sập lớp trong quá trình tìm kiếm cấu trúc.

5 Đề xuất phương pháp MDEP

5.1 Ý tưởng tổng thể

MDEP mô hình hóa tương tác giữa Microglia và Astrocyte như một hệ đa tác nhân trên đồ thị tính toán của mạng nơ-ron. Trong đó:

- **Microglia** đảm nhiệm vai trò phát hiện và loại bỏ các liên kết có giá trị thấp đối với cả hiệu năng dự đoán lẫn khả năng nhận thức nhiều.
- **Astrocyte** đảm nhiệm vai trò khảo sát các vùng bất định nhận thức cục bộ cao, từ đó định hướng mọc lại các kết nối cần thiết để phục hồi hoặc tăng cường dung lượng biểu diễn.

Toàn bộ quá trình hướng tới cực tiểu hóa hàm mục tiêu tổng quát:

$$\mathcal{J} = \text{ECE} + \lambda \cdot \text{FLOPs},$$

trong đó thành phần thứ nhất đo sai số định cỡ, còn thành phần thứ hai phản ánh chi phí tính toán.

5.2 Tác nhân Microglia: tiêu chí cắt tĩa nhận thức bất định

Trong không gian dữ liệu y tế, nhiều đặc trưng mang thông tin mạnh lại thường xuất hiện ở các vùng có bất định nội tại rất cao. Nếu tiêu chí xếp hạng được định nghĩa bằng phép trừ tuyến tính giữa các tín hiệu, hiện tượng triệt tiêu độ lớn có thể xảy ra và khiến hệ thống cắt nhầm các kết nối quan trọng. Vì vậy, điểm số cắt tĩa của Microglia được tái định nghĩa thành phép cộng của hai vai trò sau, kết hợp chuẩn hóa trên từng lớp:

$$C_{ij}^{(t)} = \text{Norm} \left(\left| w_{ij} \frac{\partial \mathcal{L}_{EDL}}{\partial w_{ij}} \right| \right) + \beta \cdot \text{Norm} \left(\left| w_{ij} \frac{\partial u_a}{\partial w_{ij}} \right| \right).$$

Hàm này mang ý nghĩa rằng một liên kết cần được bảo vệ nếu nó đóng góp lớn vào việc giảm sai số dự đoán hoặc đóng góp lớn vào việc mô hình hóa nhận thức nhiều của ảnh. Chỉ những liên kết có C_{ij} thấp nhất, tức gần như vô ích ở cả hai phương diện, mới bị loại bỏ.

Để kiểm soát chi phí tính toán, đạo hàm của u_a không được tính ở mọi mini-batch mà chỉ trong các chu kỳ cập nhật cấu trúc cách nhau ΔT bước. Tại mỗi lần cập nhật như vậy, quá trình truyền ngược chỉ cần chạy trên một mini-batch đại diện. Nhờ chiến lược khấu hao này, chi phí bổ sung của MDEP tiệm cận mức của RigL nhưng giàu thông tin bất định hơn.

5.3 Tác nhân Astrocyte: bất định nhận thức cục bộ và tăng trưởng kết nối

Astrocyte được thiết kế để phản ứng với các vùng mà mô hình còn thiếu hiểu biết. Vì $u_e = K/S$ là một hàm khả vi toàn cục, đề tài xác định bất định nhận thức cục bộ tại nơ-ron i của lớp l bằng:

$$u_{e,i}^{(node)} = \left| \frac{\partial u_e}{\partial \mathbf{a}_i^{(l)}} \right|.$$

Việc tính gradient này đòi hỏi luồng truyền ngược đi qua cả các liên kết đang “ngủ đông”, tức là một *dense gradient pass*. Để tránh nhiễu gradient mạnh của STE nguyên bản trong mạng cực thưa, đề tài áp dụng Smoothed Straight-Through Estimator:

$$\frac{\partial M_{ij}}{\partial S_{ij}} \approx \sigma'(S_{ij}/\gamma),$$

với γ là nhiệt độ được ủ giảm dần theo thời gian.

Tiềm năng mọc mới của một kết nối được xác định theo:

$$G_{ij}^{(t)} = \text{Norm} \left(u_{e,i}^{(node)} \right) \times \text{Norm} \left(\left| \frac{\partial \mathcal{L}_{EDL}}{\partial w_{ij}} \right| \right).$$

Những vị trí có G_{ij} cao nhất sẽ được ưu tiên kích hoạt trở lại, giúp mạng phân bổ dung lượng vào các vùng còn bất định nhưng có tiềm năng cải thiện rõ rệt đối với chất lượng dự đoán.

5.4 Ràng buộc phần cứng và động lực huấn luyện

Một điểm thực dụng của đề tài là mọi cập nhật cấu trúc đều phải tuân thủ nghiêm ngặt chuẩn thừa NVIDIA 2:4, nghĩa là trong mỗi nhóm bốn trọng số liền kề chỉ giữ lại đúng hai trọng số. Điều này tăng khả năng chuyển hóa sự thừa thớt về mặt thuật toán thành tăng tốc thực tế trên GPU hiện đại.

Quá trình huấn luyện gồm hai pha chính:

- **Warm-up:** mạng ban đầu học ở chế độ đặc và tĩnh trong khoảng 15–20% số epoch để các tín hiệu bất định trở nên có nghĩa.
- **Dynamic sparsity:** sau pha khởi động, mạng được cắt tỉa và tái sinh dần theo lịch trình cosine, hướng đến hình thái thừa chuẩn 2:4.

6 Đảm bảo lý thuyết kỳ vọng

Đề tài đặt trọng tâm mạnh vào tính chặt chẽ toán học, trong đó các bảo đảm về hội tụ hình thái và chống sập lớp đã được tích hợp trực tiếp vào phần cơ sở lý thuyết và thiết kế phương pháp. Về bản chất, MDEP không chỉ là một heuristic cắt tỉa dựa trên tín hiệu bất định, mà là một khung tối ưu hóa cấu trúc được xây dựng trên nền tảng liên tục, gradient có chệch giảm dần và cơ chế bù trừ giữa hai tác nhân để duy trì khả năng lan truyền gradient trong quá trình học.

7 Đề xuất Evidential Focal Loss cho dữ liệu mất cân bằng

Đối với các bộ dữ liệu y tế cực mất cân bằng như ISIC 2024, việc kết hợp trực tiếp Focal Loss tiêu chuẩn với EDL chứa đựng một nghịch lý toán học nghiêm trọng. Nếu dùng trọng số $(1 - \hat{p}_c)^\gamma$ để tác động trực tiếp lên lượng bằng chứng, phân phối Dirichlet của lớp thiểu số có thể bị ép ngược về gần prior, làm tổng bằng chứng S giảm mạnh và gây bùng nổ bất định nhận thức. Khi đó, mô hình có xu hướng trả lời “tôi không biết” thay vì thật sự học được cách nhận diện lớp hiếm.

Để khắc phục, đề tài đề xuất *Evidential Focal Loss* (EFL):

$$\mathcal{L}_{EFL} = \sum_{c=1}^K (1 - \hat{p}_c)^\gamma \mathcal{L}_{\mathcal{T}-EDL}^{(c)}, \quad \hat{p}_c = \frac{\alpha_c}{S}.$$

Điểm cốt lõi của EFL là hệ số focal chỉ tác động lên hàm mất mát chứ không bóp méo trực tiếp không gian bằng chứng. Nhờ đó, EDL vẫn duy trì được cấu trúc Dirichlet hợp lệ, trong khi gradient dành cho các mẫu khó và lớp hiếm được tăng cường một cách có kiểm soát.

8 Kế hoạch thực nghiệm và đánh giá

Để kiểm chứng giả thuyết nghiên cứu, đề tài đề xuất một giao thức đánh giá nhấn mạnh đồng thời hiệu năng, độ tin cậy và chi phí tính toán.

8.1 Các mô hình đối chuẩn

Nhóm đối chuẩn dự kiến bao gồm:

- các phương pháp DST tiêu biểu như RigL và SNIP;
- các phương pháp cắt tỉa Bayes như Variational Dropout và L_0 Regularization;
- các biến thể EDL tính để đánh giá lợi ích thuần túy của tối ưu hình thái.

8.2 Thước đo đánh giá

Các chỉ số đánh giá không chỉ tập trung vào độ chính xác mà còn bao gồm cả độ tin cậy và hiệu quả tính toán:

- Balanced Accuracy;
- Macro-AUROC;
- ECE và đặc biệt là Minority-ECE cho nhóm bệnh lý thiểu số;
- Training FLOPs/MACs và khả năng tăng tốc thực tế trên phần cứng hỗ trợ chuẩn 2:4.

Những thước đo này được lựa chọn nhằm tránh tình trạng hiệu năng của lớp đa số che lấp thất bại của mô hình trên các lớp bệnh lý hiếm, vốn là trọng tâm đánh giá trong bối cảnh y tế.

8.3 Nghiên cứu cắt lớp

Thiết kế ablation study gồm ba cấu hình:

- **MDEP-PruneOnly:** loại Astrocyte để đo tác động khi chỉ cắt tỉa mà không có mọc bù.
- **MDEP-GrowOnly:** loại Microglia để đánh giá mức tăng bất định và nguy cơ học vẹt nhiễu.
- **MDEP đầy đủ:** kiểm chứng hiệu quả cộng hưởng giữa hai tác nhân.

9 Đóng góp khoa học kỳ vọng

Nếu thực hiện thành công, đề tài có thể tạo ra các đóng góp nổi bật sau:

- Đóng góp 1.** Đề xuất một khung cấu trúc động mới có nhận thức bất định, kết nối hai dòng nghiên cứu EDL và DST vốn đang tương đối tách rời.
- Đóng góp 2.** Xây dựng một cơ chế tối ưu hóa đa tác nhân có thể diễn giải được, trong đó vai trò cấu trúc và tăng trưởng được tách biệt rõ ràng theo bản chất tín hiệu bất định.
- Đóng góp 3.** Bổ sung cơ sở lý thuyết về hội tụ cấu trúc dưới gradient có chệch và cận xác suất chống sập lớp.
- Đóng góp 4.** Đưa ra hàm EFL phù hợp cho dữ liệu y tế siêu mất cân bằng, qua đó tăng tính thực dụng của EDL trong môi trường lâm sàng.
- Đóng góp 5.** Đảm bảo khả năng triển khai phần cứng bằng chuẩn thừa có cấu trúc, vượt qua hạn chế thường gặp của thừa thớt phi cấu trúc.

10 Lộ trình triển khai đề tài

Đề tài được định hướng triển khai trong 24 tháng theo các giai đoạn sau:

Giai đoạn	Nội dung công việc chính
Tháng 1–4	Hoàn thiện dẫn xuất toán học cho Smoothed STE, EFL và cơ chế đạo hàm bất định cục bộ trên PyTorch.
Tháng 5–9	Xây dựng khung đa tác nhân MDEP, tích hợp lịch cập nhật khấu hao và ràng buộc thừa NVIDIA 2:4.
Tháng 10–13	Tối ưu siêu tham số như β , γ và các lịch trình học; triển khai nghiên cứu cấu trúc lớp.
Tháng 14–18	Đối chuẩn trên dữ liệu lâm sàng, đặc biệt là ISIC 2024, với các chỉ số Macro-AUROC và Minority-ECE.
Tháng 19–24	Hoàn thiện mã nguồn mở, chuẩn bị báo cáo tổng kết và nộp bài báo khoa học.

11 Kết luận

MDEP là một đề xuất có tính mới ở giao điểm của ba hướng nghiên cứu quan trọng: định lượng bất định, tối ưu hóa cấu trúc mạng và tăng tốc phần cứng. Khác với các phương pháp cấu trúc truyền thống vốn chỉ quan tâm đến độ lớn tham số, MDEP sử dụng trực tiếp tín hiệu bất định để quyết định nên loại bỏ hay phục hồi kết nối nào. Đồng thời, đề tài không dừng ở mức ý tưởng heuristic mà còn đặt ra mục tiêu chứng minh hội tụ và chống sập lớp dưới khuôn khổ xấp xỉ ngẫu nhiên có chệch.

Về mặt ứng dụng, đề tài đặc biệt phù hợp với các bài toán y tế nơi độ tin cậy của mô hình quan trọng không kém độ chính xác. Nếu được kiểm chứng thực nghiệm thành công, MDEP có thể trở thành một nền tảng đáng chú ý cho thế hệ mô hình học sâu vừa gọn nhẹ, vừa có khả năng tự nhận biết mức độ không chắc chắn của chính mình.

Từ khóa

Học sâu bằng chứng; định lượng bất định; mạng thưa động; Microglia; Astrocyte; Evidential Focal Loss; NVIDIA 2:4 sparsity; dữ liệu y tế mất cân bằng.